

Mục lục

1	Giới thiệu đề tài	3
2	Mô tả bài toán	3
3	Mô tả Tập dữ liệu (Dataset)	4
3.1	Kích thước và cấu trúc dữ liệu	4
3.2	Các đặc trưng số học	4
4	Khám phá dữ liệu (Exploratory Data Analysis - EDA)	4
4.1	Loại bỏ các trường dữ liệu nhiễu	5
4.2	Phân phối của biến mục tiêu (Target Distribution)	5
4.3	Phát hiện ngoại lai (Outlier Detection)	6
4.4	Đánh giá khả năng phân tách của các đặc trưng (Feature Separability Analysis)	7
4.5	Phân tích đa cộng tuyến (Multicollinearity Analysis)	9
5	Tiền xử lý dữ liệu và Lựa chọn đặc trưng	9
5.1	Mã hóa nhãn mục tiêu (Label Encoding)	10
5.2	Lựa chọn đặc trưng (Feature Selection)	10
5.3	Chuẩn hóa dữ liệu (Feature Scaling)	10
6	Cơ sở lý thuyết các phương pháp tiếp cận	11
6.1	Logistic Regression	11
6.2	Cây quyết định (Decision Tree - CART)	12
7	Xây dựng và Cài đặt thuật toán Custom CART	13
7.1	Quy trình cài đặt	13
7.2	Lý do chọn phương pháp Cây quyết định cho y tế	14
8	Thử nghiệm và Đánh giá	14
8.1	Thiết lập kịch bản thực nghiệm	14
8.2	Ý nghĩa của các chỉ số đánh giá y tế	14
8.3	Tối ưu siêu tham số (Hyperparameter Tuning)	15
8.4	Phân tích kết quả của mô hình tự cài (Custom CART)	15
9	So sánh các mô hình	19
10	Triển khai ứng dụng (Deployment)	19

11 Kết luận và Hướng phát triển	21
11.1 Kết luận	21
11.2 Phát triển	21

Danh sách hình vẽ

1	Biểu đồ phân phối của biến mục tiêu diagnosis ($M=1$, $B=0$)	6
2	Biểu đồ boxplot	7
3	Biểu đồ phân phối mật độ (KDE) của các đặc trưng sinh học, phân nhóm theo khối u Lành tính và Ác tính.	8
4	Biểu đồ heatmap	9
5	Ma trận nhầm lẫn (Confusion Matrix) và Báo cáo phân loại (Classification Report) của mô hình Logistic Regression.	12
6	Báo cáo phân loại (Classification Report) của DT.	16
7	Confusion matrix của DT.	16
8	Cây quyết định tối ưu nhất	18
9	Giao diện web của hệ thống dự đoán ung thư vú	20
10	Kết quả của quá trình huấn luyện	23
11	Biểu đồ so sánh các mô hình	24

Danh sách bảng

1	Bảng so sánh độ chính xác của các mô hình thực nghiệm	19
2	Bảng phân công nhiệm vụ trong nhóm	25

1 Giới thiệu đề tài

Bệnh ung thư vú là một trong những căn bệnh nguy hiểm và phổ biến nhất ở phụ nữ trên toàn thế giới. Việc phát hiện và chẩn đoán sớm tính chất của khối u (lành tính hay ác tính) đóng vai trò sống còn trong việc đưa ra phác đồ điều trị kịp thời, từ đó gia tăng đáng kể tỷ lệ sống sót của bệnh nhân.

Trong những năm gần đây, sự bùng nổ của trí tuệ nhân tạo đã mang lại các công cụ hỗ trợ đắc lực cho lĩnh vực y tế. Các mô hình Học máy có khả năng phân tích một lượng lớn thông số y khoa trong thời gian ngắn để đưa ra các dự đoán có độ tin cậy cao, đóng vai trò như một chuyên gia tham vấn cho các bác sĩ.

Trong khuôn khổ Bài tập lớn học phần Học máy, nhóm tiến hành thực hiện **Đề tài 12: Xây dựng mô hình cây quyết định hỗ trợ chẩn đoán bệnh ung thư**. Trọng tâm của đề tài là ứng dụng thuật toán Học máy để dự đoán nhân khối u trên tập dữ liệu Breast Cancer Wisconsin. Bên cạnh việc sử dụng các thư viện có sẵn, báo cáo này chú trọng vào việc tự cài đặt thuật toán Cây quyết định (Decision Tree - CART) từ đầu và tối ưu tham số để đưa ra mô hình hỗ trợ tốt nhất. Điều này không chỉ giúp nhóm nắm vững bản chất toán học của thuật toán mà còn xây dựng được một mô hình có tính minh bạch và khả năng giải thích cao – yếu tố mang tính tiên quyết trong các ứng dụng chẩn đoán y tế.

2 Mô tả bài toán

Dưới góc độ Học máy, việc chẩn đoán ung thư dựa trên các đặc trưng sinh thiết là một bài toán Phân loại nhị phân thuộc nhóm Học có giám sát.

- **Đầu vào (Input - X):** Một vector chứa các đặc trưng số học được trích xuất từ hình ảnh số hóa của chọc hút bằng kim nhỏ trên khối u vú. Các đặc trưng này mô tả đặc điểm của nhân tế bào (ví dụ: bán kính, kết cấu, chu vi, diện tích, độ mịn,...).
- **Đầu ra (Output - y):** Nhân phân lớp của khối u thuộc một trong hai trạng thái: Lành tính (Benign - B) hoặc Ác tính (Malignant - M). Trong quá trình tính toán, nhãn này sẽ được mã hóa về dạng số học (0 cho Lành tính và 1 cho Ác tính).

Mục tiêu cốt lõi là tìm ra một hàm mục tiêu $f(X) \approx y$ sao cho sai số dự đoán trên tập dữ liệu chưa từng quan sát (tập kiểm thử) là nhỏ nhất. Đối với ngữ cảnh y tế, bài toán này đặt ra một yêu cầu khắt khe về việc tối thiểu hóa các trường hợp dự đoán sai bệnh nhân bị ung thư ác tính thành lành tính (False Negative).

3 Mô tả Tập dữ liệu (Dataset)

Tập dữ liệu được sử dụng trong dự án là Breast Cancer Wisconsin (Diagnostic) Dataset, thu thập từ nền tảng Kaggle.

3.1 Kích thước và cấu trúc dữ liệu

Dữ liệu ban đầu được cấu trúc dưới dạng một bảng bao gồm 569 bản ghi (mẫu) tương ứng với 569 bệnh nhân, và 33 cột (đặc trưng). Các cột bao gồm:

- **id:** Mã định danh duy nhất của bệnh nhân.
- **diagnosis:** Biến mục tiêu (M = Malignant / Ác tính, B = Benign / Lành tính).
- 30 cột chứa các giá trị số học mô tả chi tiết hình thái hạt nhân tế bào.
- **Unnamed: 32:** Cột chứa giá trị rỗng (NaN) do lỗi định dạng lưu trữ file CSV.

3.2 Các đặc trưng số học

Từ các hình ảnh sinh thiết tế bào, 10 đặc trưng cơ bản được tính toán cho mỗi hạt nhân bao gồm: Bán kính (Radius), Kết cấu (Texture), Chu vi (Perimeter), Diện tích (Area), Độ mịn (Smoothness), Độ nén (Compactness), Độ rỗng (Concavity), Các điểm lõm (Concave points), Độ đối xứng (Symmetry), và Chiều không gian fractal (Fractal dimension).

Đối với mỗi đặc trưng cơ bản, tập dữ liệu tính toán 3 chỉ số thống kê, tạo thành $10 \times 3 = 30$ đặc trưng dự đoán:

- **Mean:** Giá trị trung bình của các tế bào.
- **Standard Error (se):** Sai số chuẩn.
- **Worst:** Giá trị tồi tệ nhất (hoặc lớn nhất) trong các tế bào được quan sát.

4 Khám phá dữ liệu (Exploratory Data Analysis - EDA)

Bước Khám phá dữ liệu (EDA) đóng vai trò cung cấp cái nhìn tổng quan về sự phân phối của dữ liệu, phát hiện các giá trị ngoại lai và kiểm tra mức độ tương quan cơ bản trước khi đưa vào mô hình học.

4.1 Loại bỏ các trường dữ liệu nhiễu

Sau khi sử dụng phương thức `df.info()` để kiểm tra kiểu dữ liệu, nhóm nhận thấy có hai cột không mang giá trị cho việc dự đoán:

- Cột `id`: Chứa mã định danh định danh bệnh nhân. Nếu đưa vào mô hình sẽ gây ra hiện tượng học vẹt (overfitting).
- Cột `Unnamed: 32`: Cột này chứa toàn bộ giá trị khuyết thiếu (NaN) trên cả 569 dòng.


Do đó, thao tác đầu tiên là dùng hàm `drop` loại bỏ hai cột này khỏi DataFrame. Dữ liệu làm sạch còn lại 31 cột (bao gồm 1 cột nhãn và 30 cột đặc trưng). Việc kiểm tra bằng `df.isnull().sum()` xác nhận bộ dữ liệu không còn bất kỳ giá trị khuyết thiếu nào.

4.2 Phân phối của biến mục tiêu (Target Distribution)

Tập dữ liệu chứa hai nhãn phân loại:

- Nhãn **B** (**B**enign - **L**ành tính).
- Nhãn **M** (**M**alignant - **Á**c tính).


Trực quan hóa phân phối biến mục tiêu bằng biểu đồ cho thấy số lượng mẫu Lành tính chiếm ưu thế hơn so với mẫu Ác tính. Sự mất cân bằng nhẹ này vẫn nằm trong mức an toàn cho phép và không yêu cầu các kỹ thuật cân bằng dữ liệu phức tạp (như SMOTE) đối với các mô hình cây quyết định mạnh mẽ.



Hình 1: Biểu đồ phân phối của biến mục tiêu diagnosis ($M=1$, $B=0$)

4.3 Phát hiện ngoại lai (Outlier Detection)


Nhóm sử dụng biểu đồ Boxplot để trực quan hóa sự phân bố thống kê của các đặc trưng. Biểu đồ Boxplot giúp nhận diện trực quan khoảng phần tư (IQR), giá trị trung vị và đặc biệt là các điểm dữ liệu nằm ngoài "râu" (whiskers), tức là các giá trị ngoại lai (outliers). Trong dữ liệu y tế, ngoại lai thường là các trường hợp bệnh lý nghiêm trọng hoặc biến thể lạ của tế bào, do đó việc giữ lại hay xử lý ngoại lai được cân nhắc kỹ lưỡng để không làm mất đi các tín hiệu bệnh lý quan trọng.



Hình 2: Biểu đồ boxplot

4.4 Đánh giá khả năng phân tách của các đặc trưng (Feature Separability Analysis)

Thay vì chỉ quan sát phân phối chung, nhóm đã sử dụng biểu đồ KDE lồng ghép theo nhãn chẩn đoán (Diagnosis) để đánh giá trực quan "sức mạnh phân loại" của từng đặc trưng độc lập. Dựa vào mức độ chồng lấn (overlap) giữa hai đường phân phối.



Hình 3: Biểu đồ phân phối mật độ (KDE) của các đặc trưng sinh học, phân nhóm theo khối u Lành tính và Ác tính.


Nhóm đặc trưng có khả năng phân tách cao (Strong Predictors): Quan sát các biểu đồ như `concave_points_mean`, `radius_mean`, `perimeter_mean`, `area_mean` ta thấy đỉnh của hai đường phân phối cách khá xa nhau và diện tích phần giao nhau rất nhỏ. Điều này minh chứng rõ ràng về mặt y khoa: các khối u ác tính thường có kích thước lớn hơn và đường bao tế bào lồi/rỗ phức tạp hơn hẳn so với u lành tính. Đây sẽ là những "đặc trưng vàng" cung cấp lượng thông tin lớn (Information Gain cao) cho thuật toán học máy.

Nhóm đặc trưng có độ nhiễu cao (Weak Predictors): Ngược lại, ở các biểu đồ như `fractal_dimension_mean`, `texture_se`, hay `smoothness_se`, hai đường phân phối Lành/Ác gần như nằm đè lên nhau. Điều này cho thấy nếu chỉ dựa vào các thông số này, cả bác sĩ lẫn máy tính đều không thể phân biệt được tính chất của khối u.

4.5 Phân tích đa cộng tuyến (Multicollinearity Analysis)

Đa cộng tuyến xảy ra khi hai hoặc nhiều đặc trưng trong tập dữ liệu có tương quan tuyến tính rất mạnh với nhau. Điều này có thể làm giảm tính ổn định của các mô hình tuyến tính (như Logistic Regression). Nhóm đã tiến hành tính toán ma trận tương quan df.corr() và trực quan hóa qua Heatmap.

Kết quả chỉ ra rằng nhiều đặc trưng được dẫn xuất từ cùng một đặc điểm gốc mang độ tương quan cực kỳ cao (ví dụ: radius_mean, perimeter_mean và area_mean tương quan gần như tuyệt đối bằng 1.0 vì chu vi và diện tích đều được tính theo các hàm của bán kính).



Hình 4: Biểu đồ heatmap

5 Tiền xử lý dữ liệu và Lựa chọn đặc trưng

Dựa trên những phát hiện từ quá trình EDA, nhóm tiến hành luồng tiền xử lý (Data Preprocessing) bao gồm các bước sau:

5.1 Mã hóa nhãn mục tiêu (Label Encoding)

Biến mục tiêu `diagnosis` hiện đang ở định dạng chuỗi ký tự. Để tương thích với không gian toán học của các thuật toán phân loại, nhóm đã thực hiện bước mã hóa nhãn (Label Encoding) sang định dạng nhị phân. Theo quy ước chuẩn trong học máy y khoa, lớp mang bệnh lý (Positive Class) sẽ được gán giá trị 1 để thuật toán tập trung tối ưu hóa Độ nhạy (Recall) cho lớp này. Cụ thể nhóm sử dụng hàm lambda để ánh xạ:

- M (Malignant) $\rightarrow$ 1
- B (Benign) $\rightarrow$ 0

5.2 Lựa chọn đặc trưng (Feature Selection)

Dựa vào ma trận tương quan, nhóm thực hiện kỹ thuật chọn lọc nhằm khắc phục hiện tượng đa cộng tuyến. Các đặc trưng mang thông tin trùng lặp cao bị loại bỏ để giảm số chiều của bài toán, giúp mô hình bớt phức tạp, tăng tốc độ huấn luyện và giảm thiểu khả năng overfitting do nhiễu.

```
1 # feature selection
2 corr_matrix = df.corr().abs()
3 mask = np.triu(np.ones_like(corr_matrix, dtype=bool))
4 tri_df = corr_matrix.mask(mask)
5 to_drop = [x for x in tri_df.columns if any(tri_df[x] > 0.92)]
6 df = df.drop(to_drop, axis=1)
7 print(df.shape[1])
```

5.3 Chuẩn hóa dữ liệu (Feature Scaling)

Mặc dù thuật toán Decision Tree và Random Forest miễn nhiễm với sự chênh lệch thang đo, nhưng mô hình Baseline Logistic Regression lại rất nhạy cảm với điều này. Trong tập dữ liệu, các giá trị `area_worst` có thể lên tới 4254.0, trong khi `smoothness_se` chỉ xoay quanh 0.005. Do đó, một bản sao của tập dữ liệu đầu vào (X) đã được nhóm tiến hành chuẩn hóa (Standardization) dành riêng cho mô hình Logistic Regression. Bước tiền xử lý này giúp đưa các đặc trưng về cùng một hệ quy chiếu, đảm bảo thuật toán tối ưu Gradient Descent không bị lệch hướng và hội tụ tốt trong không gian trọng số.

```

1  # scaling data for logistic regression
2  from sklearn.preprocessing import StandardScaler
3  scaler = StandardScaler()
4  X_train_scaled = scaler.fit_transform(X_train)
5  X_test_scaled = scaler.transform(X_test)

```

6 Cơ sở lý thuyết các phương pháp tiếp cận

Đề tài áp dụng các thuật toán học máy khác nhau. Trong đó, mô hình Logistic Regression và Decision Tree từ thư viện `scikit-learn` được sử dụng làm chuẩn so sánh (Baseline). Trọng tâm chính là mô hình Cây quyết định được cài đặt thủ công.

6.1 Logistic Regression

Logistic Regression là một mô hình phân loại tuyến tính cơ bản. Mô hình ước lượng xác suất dữ liệu thuộc lớp dương tính ($y = 1$) bằng cách áp dụng hàm Sigmoid lên một tổ hợp tuyến tính của các biến đầu vào:

$$P(y = 1|X) = \sigma(W^T X + b) = \frac{1}{1 + e^{-(W^T X + b)}} \quad (1)$$

Nếu $P \geq 0.5$, mô hình dự đoán lớp 1 (Ác tính), ngược lại dự đoán lớp 0 (Lành tính). Ưu điểm của mô hình này là nhanh, nhẹ và giải thích được tác động tuyến tính của từng biến, nhưng hạn chế là không nắm bắt được các mối quan hệ phi tuyến phức tạp trong dữ liệu tế bào ung thư.

L2 Regularization (Ridge) – Mặc định trong Logistic Regression của `scikit-learn` L2 Regularization bổ sung tổng bình phương các trọng số vào hàm mất mát:

$$J_{L2}(\theta) = J(\theta) + \lambda \sum_{j=1}^{30} \theta_j^2$$

Trong đó:

- $J(\theta)$ là hàm mất mát của Logistic Regression.
- λ là hệ số điều chuẩn (regularization strength).
- θ_j là trọng số của thuộc tính thứ j .

Tác dụng: L2 Regularization làm giảm độ lớn của các trọng số θ , phân bổ đều tầm quan trọng cho các biến có liên quan đến nhau, giúp mô hình ổn định và chống overfitting.

[[66 1] [2 45]]					
	precision	recall	f1-score	support	
0	0.97	0.99	0.98	67	
1	0.98	0.96	0.97	47	
accuracy			0.97	114	
macro avg	0.97	0.97	0.97	114	
weighted avg	0.97	0.97	0.97	114	

Hình 5: Ma trận nhầm lẫn (Confusion Matrix) và Báo cáo phân loại (Classification Report) của mô hình Logistic Regression.

Kết quả kiểm thử trên 114 mẫu dữ liệu độc lập cho thấy mô hình Logistic Regression đạt hiệu năng xuất sắc với độ chính xác tổng thể (*Accuracy*) lên tới 97%. Tuy nhiên, trong bài toán chẩn đoán ung thư, độ chính xác tổng thể không quan trọng bằng khả năng nhận diện đúng các ca ác tính.

- **Rủi ro Dương tính giả (False Positive – FP):** Chỉ có 1 trường hợp lành tính bị dự đoán nhầm thành ác tính.
- **Rủi ro Âm tính giả (False Negative – FN):** Mô hình đã bỏ sót 2 ca ung thư ác tính (dự đoán nhầm thành lành tính). Mặc dù chỉ số *Recall* đạt 0.96 là một kết quả tốt đối với một thuật toán tuyến tính cơ bản, nhưng trong lĩnh vực y tế, việc bỏ sót 2/47 bệnh nhân vẫn là một rủi ro đáng kể.

Nhiệm vụ của mô hình Decision Tree được phát triển ở phần tiếp theo không chỉ là duy trì hoặc vượt qua mức *Accuracy* 97% này, mà quan trọng hơn là cố gắng giảm số ca *False Negative* (FN) xuống mức 0 hoặc 1, đồng thời mang lại khả năng diễn giải trực quan thông qua các quy tắc **if-else** để hỗ trợ các bác sĩ trong quá trình ra quyết định.

6.2 Cây quyết định (Decision Tree - CART)

Mô hình Cây phân loại và hồi quy (Classification and Regression Trees - CART) hoạt động bằng cách chia không gian thuộc tính thành các vùng chữ nhật riêng biệt.

Tại mỗi nút, thuật toán tìm kiếm một thuộc tính và một ngưỡng chia sao cho dữ liệu tại các nút con trở nên đồng nhất nhất có thể (thuần khiết nhất về nhãn).

Để đánh giá độ đồng nhất (Impurity), hai độ đo phổ biến được sử dụng là Gini Index và Entropy. Chỉ số Gini cho một nút D chứa các mẫu thuộc phân lớp c được định nghĩa:

$$Gini(D) = 1 - \sum_{i=1}^C p_i^2 \quad (2)$$

Trong đó p_i là xác suất một mẫu ngẫu nhiên tại nút D thuộc về lớp i .

Tương tự, độ đo Entropy đo lường mức độ lộn xộn của thông tin:

$$Entropy(D) = - \sum_{i=1}^C p_i \log_2(p_i) \quad (3)$$

Tại mỗi bước rẽ nhánh, thuật toán tính toán sự chênh lệch độ bất thuần trước và sau khi tách, gọi là Độ lợi thông tin (Information Gain):

$$IG = Impurity(Parent) - \left(\frac{N_{left}}{N} Impurity(Left) + \frac{N_{right}}{N} Impurity(Right) \right) \quad (4)$$

Thuật toán sẽ tham lam (greedy) chọn đặc trưng và ngưỡng phân tách tối đa hóa giá trị Information Gain này.

7 Xây dựng và Cài đặt thuật toán Custom CART

Thay vì gọi các hàm đóng gói sẵn như một hộp đen (black-box), yêu cầu quan trọng của báo cáo là nghiên cứu và tự cài đặt thuật toán Cây quyết định (Custom CART). Việc cài đặt được thực hiện hoàn toàn thủ công bằng ngôn ngữ Python, sử dụng các thư viện tính toán ma trận cơ bản như NumPy.

7.1 Quy trình cài đặt

Mô hình Custom CART được xây dựng với hai lớp chính: **Node** (đại diện cho một đỉnh của cây) và **DecisionTree** (đại diện cho luồng thực thi tổng thể).

Thuật toán đệ quy xây dựng cây:

1. **Kiểm tra điều kiện dừng:** Đệ quy dừng lại và trả về Nút Lá chứa nhãn chiếm đa số nếu:

- Đạt đến độ sâu tối đa cho phép (**max_depth**).

- Số lượng mẫu tại nút hiện tại nhỏ hơn số lượng tối thiểu để phân tách (`min_samples_split`).
 - Số lượng mẫu trong nút hoàn toàn thuộc về 1 lớp duy nhất (Pure node).
 - Độ lợi thông tin lớn nhất tính được không vượt qua một ngưỡng tối thiểu (`min_gain`).
2. **Tìm kiếm điểm tách tốt nhất (Best Split):** Tại nút hiện tại, lặp qua toàn bộ các đặc trưng và tất cả các giá trị độc nhất của từng đặc trưng làm ngưỡng chia thử nghiệm. Tính Information Gain cho mỗi phép chia. Lựa chọn ngưỡng và đặc trưng cho Information Gain cao nhất.
 3. **Tách dữ liệu và gọi đệ quy:** Dữ liệu được chia làm 2 tập nhánh trái ($X \leq \text{ngng}$) và nhánh phải ($X > \text{ngng}$). Tiếp tục đệ quy xây dựng cho nhánh trái và nhánh phải.

7.2 Lý do chọn phương pháp Cây quyết định cho y tế

Lý do nhóm tập trung cài đặt Cây quyết định thay vì Mạng Neural sâu là vì tính giải thích được (Interpretability). Trong chẩn đoán y tế, các bác sĩ không thể tin tưởng một mô hình dự đoán ra kết quả mà không hiểu rõ nguyên nhân. Cây quyết định có khả năng "dịch" kết quả máy học thành các luật logic *Nếu - Thì* rõ ràng, ví dụ: "*Nếu diện tích hạt nhân lớn hơn 783.6 và độ lõm lớn hơn 0.14, thì là u ác tính*". Điều này trực tiếp hỗ trợ y bác sĩ kiểm chứng và đưa ra quyết định.

8 Thử nghiệm và Đánh giá

8.1 Thiết lập kịch bản thực nghiệm

Dữ liệu đã qua tiền xử lý được chia ngẫu nhiên thành hai tập: Tập huấn luyện (Training Set) và Tập kiểm thử (Test Set). Các mô hình sẽ chỉ được học trên tập Training và bị đánh giá độ chính xác trên tập Test hoàn toàn xa lạ nhằm phản ánh đúng khả năng tổng quát hóa của chúng trên thực tế.

8.2 Ý nghĩa của các chỉ số đánh giá y tế

Việc đánh giá không chỉ dựa vào Độ chính xác tổng thể (Accuracy) mà còn cần xem xét cấu trúc của Ma trận nhầm lẫn (Confusion Matrix). Đối với bài toán dự đoán ung thư, các chỉ số sau được sử dụng:

- **Accuracy (Độ chính xác):** Tỷ lệ dự đoán đúng trên tổng số dự đoán.
- **Precision (Độ chuẩn xác):** Tỷ lệ ca thực sự ác tính trong số các ca được mô hình kết luận là ác tính. $Precision = \frac{TP}{TP+FP}$.
- **Recall (Độ nhạy):** Tỷ lệ ca được phát hiện ác tính trong tổng số bệnh nhân thực sự mắc ung thư ác tính. $Recall = \frac{TP}{TP+FN}$.

Nhấn mạnh ngữ cảnh bài toán: Trong y tế, chỉ số Recall là quan trọng bậc nhất. Nếu mô hình dự đoán nhầm người khỏe mạnh thành ung thư (False Positive), bệnh nhân chỉ tốn thêm chi phí làm xét nghiệm chuyên sâu. Tuy nhiên, nếu mô hình bỏ sót bệnh nhân thực sự mang khối u ác tính, chẩn đoán nhầm thành lành tính (False Negative), bệnh nhân sẽ mất đi thời điểm vàng để điều trị, dẫn đến hậu quả tử vong. Do đó, mô hình được kỳ vọng tối ưu hóa Recall lên mức cao nhất có thể.

8.3 Tối ưu siêu tham số (Hyperparameter Tuning)

Để mô hình Cây quyết định tự cài đặt đạt được hiệu suất tốt nhất, nhóm đã tiến hành áp dụng chiến lược tìm kiếm theo lưới (Grid Search) để tìm ra bộ siêu tham số (Hyperparameters) tối ưu nhất, tránh việc cây quá sâu dẫn đến Overfitting hoặc quá nông dẫn đến Underfitting.

Bộ tham số được đưa vào thử nghiệm:

- `max_depth`: Thử các độ sâu từ nông đến sâu.
- `min_samples_split`: Số mẫu tối thiểu tại một nút.
- `min_gain`: Mức cải thiện thông tin tối thiểu.

Bộ tham số tối ưu (Best Parameters) tìm được:

- `max_depth`: 3
- `min_samples_split`: 5
- `min_gain`: 0.001

8.4 Phân tích kết quả của mô hình tự cài (Custom CART)

Mô hình Custom CART sau khi tối ưu siêu tham số đã cho thấy một kết quả cực kỳ ấn tượng:

```

--- BÁO CÁO PHÂN LOẠI ---


```

	precision	recall	f1-score	support
Lành tính (0)	0.98	0.91	0.95	67
Ác tính (1)	0.88	0.98	0.93	47
accuracy			0.94	114
macro avg	0.93	0.94	0.94	114
weighted avg	0.94	0.94	0.94	114

Hình 6: Báo cáo phân loại (Classification Report) của DT.

- Độ chính xác (Accuracy): Đạt khoảng **93.86%**.
- Độ nhạy (Recall): Đạt mức rất cao **97.87%**.

Ma trận nhầm lẫn (Confusion Matrix) - Mô hình tự build



Hình 7: Confusion matrix của DT.

article [utf8]inputenc [vietnamese]babel amsmath

Dựa trên ma trận nhầm lẫn (Confusion Matrix) của mô hình tự build, các giá trị thành phần được xác định như sau:

- True Positive (TP) = 46
- True Negative (TN) = 61
- False Positive (FP) = 6
- False Negative (FN) = 1

1. Độ chính xác tổng thể (Accuracy)

Công thức tính tổng tỷ lệ các mẫu được dự đoán đúng (cả Lành tính và Ác tính) trên toàn bộ tập dữ liệu kiểm thử:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

Thay số vào công thức:

$$\text{Accuracy} = \frac{46 + 61}{46 + 61 + 6 + 1} = \frac{107}{114} \approx 0.9386 \quad (\text{tương ứng } 93.86\%)$$

2. Độ nhạy (Recall / Sensitivity) - Tập trung vào lớp Ác tính (1)

Công thức tính tỷ lệ bệnh nhân mắc ung thư ác tính thực tế được mô hình nhận diện chính xác, không bị bỏ sót:

$$\text{Recall} = \frac{TP}{TP + FN}$$

Thay số vào công thức:

$$\text{Recall} = \frac{46}{46 + 1} = \frac{46}{47} \approx 0.9787 \quad (\text{tương ứng } 97.87\%)$$

3. Độ chính xác dự đoán (Precision) - Tập trung vào lớp Ác tính (1)

Công thức tính tỷ lệ ca thực sự mắc bệnh trên tổng số ca mà mô hình đã đưa ra cảnh báo là Ác tính:

$$\text{Precision} = \frac{TP}{TP + FP}$$

Thay số vào công thức:

$$\text{Precision} = \frac{46}{46 + 6} = \frac{46}{52} \approx 0.8846 \quad (\text{tương ứng } 88.46\%)$$

4. Điểm F1 (F1-Score) - Lớp Ác tính (1)

Giá trị trung bình điều hòa (Harmonic Mean) giữa Precision và Recall, đại diện cho hiệu năng tổng thể của mô hình trên lớp dữ liệu mục tiêu:


$$\text{F1-Score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

Thay số vào công thức:

$$\text{F1-Score} = 2 \times \frac{0.8846 \times 0.9787}{0.8846 + 0.9787} = 2 \times \frac{0.8657}{1.8633} \approx 0.9292 \quad (\text{tương ứng } 92.92\%)$$

Kết quả này khẳng định mô hình do nhóm lập trình từ con số 0 đã hoạt động chính xác và đạt mức hiệu năng thực tế. Việc Recall đạt 97.87% chứng tỏ thuật toán đã bắt giữ gần như toàn bộ các đặc điểm của bệnh nhân ung thư ác tính. Đồng thời f1-score cũng đạt 92.92% minh chứng cho sự cân bằng vững chắc giữa độ nhạy và độ chuẩn xác, đáp ứng tiêu chuẩn an toàn cho chẩn đoán y tế sơ bộ.

Dưới đây là sơ đồ cây quyết định bằng văn bản do thuật toán tự động in ra sau khi huấn luyện, cho thấy cơ chế suy luận của mô hình:



Hình 8: Cây quyết định tối ưu nhất

9 So sánh các mô hình

Việc đánh giá được so chiếu thông qua tất cả các mô hình cài đặt. Kết quả thực nghiệm của các thuật toán được tổng hợp trong bảng dưới đây:

Bảng 1: Bảng so sánh độ chính xác của các mô hình thực nghiệm

Mô hình (Model)	Độ chính xác (Accuracy Score)
Logistic Regression (Sklearn)	0.973684 (97.37%)
Decision Tree (Sklearn)	0.929825 (92.98%)
Custom CART (Tự cài đặt)	0.9386 (93.86%)

Nhận xét từ bảng kết quả:

- **Logistic Regression** hoạt động như một baseline mạnh với độ chính xác 97.37%, do dữ liệu sau khi tiền xử lý có tính chất phân tách tuyến tính khá tốt.
- **Custom CART** đạt Accuracy 93.86% (thậm chí cao hơn cây quyết định mặc định của Scikit-Learn trên cùng tham số). Dù thấp hơn các mô hình học sâu hoặc rừng ngẫu nhiên một chút, nhưng với Recall 97.87% cùng việc xuất ra các quy luật chẩn đoán rõ ràng, đây là mô hình có tính ứng dụng lâm sàng cao nhất, đóng vai trò then chốt trong báo cáo này.

10 Triển khai ứng dụng (Deployment)

Để tích hợp luồng xử lý dữ liệu và mô hình đã huấn luyện thành một dịch vụ có thể sử dụng trong thực tế, nhóm đã xây dựng một ứng dụng web sử dụng Flask framework. Mô hình được triển khai là `DecisionTreeClassifier` với các tham số `criterion="entropy", max_depth=3, min_impurity_decrease=0.001` và `min_samples_split=5`. Mô hình được huấn luyện trên tập Wisconsin Breast Cancer Dataset gồm 569 mẫu dữ liệu. Sau quá trình tiền xử lý, các cột có tương quan cao với hệ số Pearson lớn hơn 0.92 được loại bỏ, còn lại 22 đặc trưng đầu vào được sử dụng cho quá trình huấn luyện.

Toàn bộ pipeline huấn luyện và metadata của mô hình, bao gồm các chỉ số đánh giá như `accuracy`, `precision_malignant`, `recall_malignant`, `f1_malignant` và thời gian huấn luyện, được tuần tự hóa bằng thư viện `joblib` và lưu vào tệp `breast_cancer_decision_tree.joblib`. Việc lưu mô hình dưới dạng tệp giúp ứng dụng có thể nạp lại mô hình đã huấn luyện để dự đoán mà không cần thực hiện huấn luyện lại.

Ứng dụng Flask cung cấp ba REST API endpoints chính. Endpoint GET `/api/health` dùng để kiểm tra trạng thái hoạt động của hệ thống, đồng thời trả về thông tin phiên

bản mô hình và thời gian huấn luyện. Endpoint GET `/api/model-info` trả về schema chi tiết của mô hình, bao gồm danh sách 22 đặc trưng đầu vào, các chỉ số đánh giá và một số ví dụ dữ liệu mẫu. Endpoint POST `/api/predict` nhận dữ liệu JSON theo định dạng `{"features": {...}}`, trong đó phần `features` chứa giá trị của 22 đặc trưng sinh thiết. Sau đó, ứng dụng gọi mô hình đã được nạp từ tệp `joblib` để tính toán và trả về kết quả dự đoán gồm `prediction` nhận giá trị 0 hoặc 1, `diagnosis` tương ứng với `Benign` hoặc `Malignant`, cùng xác suất lành tính `benign_probability` và xác suất ác tính `malignant_probability`.

Về phía giao diện người dùng, ứng dụng phục vụ một trang web HTML tĩnh cho phép nhập 22 thông số sinh thiết, bao gồm các nhóm đặc trưng như `radius`, `texture`, `perimeter`, `area`, `smoothness`, `compactness`, `concavity`, `concave points`, `symmetry` và `fractal dimension` ở ba nhóm `mean`, `se` và `worst`. Giao diện được thiết kế bằng CSS tùy chỉnh, kết hợp với JavaScript trong tệp `static/app.js` để thực hiện gọi bất đồng bộ tới endpoint `/api/predict`. Kết quả chẩn đoán được hiển thị trực quan trên giao diện, kèm theo biểu đồ xác suất giúp người dùng dễ dàng quan sát mức độ tin cậy của dự đoán.

Hình 9: Giao diện web của hệ thống dự đoán ung thư vú

Với cách triển khai này, bác sĩ hoặc người dùng chỉ cần nhập các thông số sinh thiết của bệnh nhân trên giao diện web. Ứng dụng sẽ sử dụng mô hình đã lưu để đưa ra kết quả dự đoán tức thời mà không cần huấn luyện lại. Điều này giúp quá trình sử dụng mô hình trở nên thuận tiện hơn, đồng thời tách biệt rõ ràng giữa giai đoạn huấn luyện mô hình và giai đoạn suy luận trong thực tế.

Để đảm bảo độ tin cậy của hệ thống, nhóm đã xây dựng bộ kiểm thử sử dụng `unittest` kết hợp với Flask test client. Bộ kiểm thử bao gồm năm trường hợp chính: kiểm tra endpoint `/api/health`, kiểm tra endpoint `/api/model-info` có trả về đầy

đủ các trường dữ liệu cần thiết, kiểm tra dự đoán với mẫu lành tính, kiểm tra dự đoán với mẫu ác tính và kiểm tra xử lý lỗi khi dữ liệu đầu vào bị thiếu đặc trưng. Toàn bộ mã nguồn được tổ chức theo cấu trúc rõ ràng, bao gồm `app.py` cho ứng dụng chính, `train_model.py` cho quá trình huấn luyện, `templates/index.html` cho giao diện, thư mục `static/` chứa CSS và JavaScript, `tests/test_app.py` cho kiểm thử, và `src/breast_cancer_prediction.ipynb` cho notebook phân tích dữ liệu.

11 Kết luận và Hướng phát triển

11.1 Kết luận

Thông qua đề án này, nhóm đã nghiên cứu, xây dựng và đánh giá thành công các mô hình Học máy ứng dụng trong bài toán chẩn đoán ung thư vú. Cụ thể:

- Trải qua quy trình phân tích và chuẩn bị dữ liệu (EDA, Preprocessing, Feature Selection) bài bản, khắc phục được rào cản đa cộng tuyến và nhiễu dữ liệu. đề tài đã nghiên cứu, xây dựng và đánh giá thành công các mô hình Học máy ứng dụng trong bài toán chẩn đoán ung thư vú.
- Hiểu sâu về cấu trúc toán học của cây quyết định khi trực tiếp code thuật toán CART tính toán Gini/Entropy. Mô hình tự xây dựng mang lại độ tin cậy thực tiễn rất cao (Recall 97.87%).
- Từ cấu trúc cây được in ra, nhóm nhận ra tầm quan trọng cốt lõi của các đặc trưng sinh thiết bao gồm `concave points_worst`, `area_worst`, `texture_mean` và `concavity_worst`. Đây chính là các thông số then chốt quyết định đến chẩn đoán ung thư mà các bác sĩ cần đặc biệt lưu tâm.

11.2 Phát triển

- Xây dựng giao diện phần mềm (UI) cho phép nhập dữ liệu y khoa từ file CSV và trực quan hóa sơ đồ cây kết quả ngay trên màn hình thao tác của bác sĩ.
- Triển khai ứng dụng mô hình lên Cloud để phục vụ việc tham vấn trực tuyến từ xa.
- **Thành quả của Cây quyết định (Decision Tree):** Mô hình đảm bảo tính minh bạch (*White-box Model*) thông qua bộ quy tắc chẩn đoán `if-else` trực quan, giúp bác sĩ dễ dàng theo dõi và đối chiếu quá trình đưa ra quyết định của hệ thống.

- **Hạn chế tồn đọng:** Mô hình cây quyết định đơn lẻ có phương sai cao (*High Variance*) và dễ xảy ra hiện tượng *Overfitting*, dẫn đến sự thiếu ổn định khi dự đoán trên dữ liệu mới và làm gia tăng nguy cơ xuất hiện các trường hợp *False Negative* (bỏ sót bệnh nhân mắc ung thư).
- **Giải pháp tối ưu hóa (Random Forest):** Nhóm sử dụng phương pháp học tập kết hợp (*Ensemble Learning*) cùng kỹ thuật *Bagging*. Việc tổng hợp kết quả dự đoán theo cơ chế "bỏ phiếu đa số" từ nhiều cây quyết định được xây dựng ngẫu nhiên giúp giảm đáng kể nhược điểm của cây đơn lẻ, nâng cao độ ổn định của mô hình, cải thiện độ nhạy (*Recall*) và tăng độ chính xác tổng thể (*Accuracy*).
- Dự đoán cuối cùng được đưa ra bằng cách "bỏ phiếu đa số" (Majority Voting) từ tất cả các cây thành phần. RF giúp giải quyết điểm yếu chí mạng của Cây quyết định đơn lẻ là hiện tượng *overfitting* và phương sai cao (*high variance*), cung cấp độ chính xác vượt trội.

```

1  from sklearn.metrics import accuracy_score, confusion_matrix,
    ↪ classification_report
2  print("Độ chính xác trên tập Train:", accuracy_score(y_train,
    ↪ rand_clf.predict(X_train)))
3  rand_clf_acc = accuracy_score(y_test, rand_clf.predict(X_test))
4  print("Độ chính xác trên tập Test (threshold =
    ↪ 0.5):", rand_clf_acc)
5  y_pred_prob = rand_clf.predict_proba(X_test)[: , 1]
6
7  # Giảm ngưỡng threshold để bắt được các ca ác tính tốt hơn
8  custom_threshold = 0.4
9  y_pred_custom = (y_pred_prob >= custom_threshold).astype(int)
10 print("Confusion matrix với
    ↪ threshold=0.5\n", confusion_matrix(y_test,
    ↪ rand_clf.predict(X_test)))
11 print("Confusion matrix với
    ↪ threshold=0.4\n", confusion_matrix(y_test, y_pred_custom))
12 print(classification_report(y_test, y_pred_custom))

```

```


Độ chính xác trên tập Train: 0.9934065934065934
Độ chính xác trên tập Test (threshold = 0.5): 0.9824561403508771
Confusion matrix với threshold=0.5
[[66  1]
 [ 1 46]]
Confusion matrix với threshold=0.4
[[65  2]
 [ 0 47]]

```

	precision	recall	f1-score	support
0	1.00	0.97	0.98	67
1	0.96	1.00	0.98	47
accuracy			0.98	114
macro avg	0.98	0.99	0.98	114
weighted avg	0.98	0.98	0.98	114

Hình 10: Kết quả của quá trình huấn luyện

- Khi sử dụng thiết lập mặc định, mô hình **Random Forest (RF)** đạt độ chính xác tổng thể (*Accuracy*) là **98%**. Mặc dù mô hình *Ensemble* này giải quyết hiệu quả hiện tượng *Overfitting* của cây quyết định đơn lẻ (thể hiện qua khoảng cách nhỏ giữa điểm số trên tập huấn luyện và tập kiểm thử), mô hình vẫn bỏ sót 2 ca ung thư ác tính (*False Negative*).
- Để biến **Random Forest** thành một hệ thống tầm soát an toàn hơn, nhóm đã can thiệp vào cơ chế ra quyết định của mô hình bằng cách hạ ngưỡng xác suất (*Threshold*) xuống mức **0.4**. Điều này có nghĩa là chỉ cần khoảng **40%** số cây trong “rừng” dự đoán một mẫu là ác tính, hệ thống sẽ ngay lập tức đưa ra cảnh báo **Ác tính** để bác sĩ tiếp tục thực hiện các xét nghiệm chuyên sâu như sinh thiết.
- Việc điều chỉnh ngưỡng này giúp tăng khả năng phát hiện các ca ung thư thực sự, giảm nguy cơ bỏ sót bệnh nhân mắc ung thư (*False Negative*), mặc dù có thể làm tăng nhẹ số trường hợp cảnh báo nhầm (*False Positive*).



Hình 11: Biểu đồ so sánh các mô hình